

# **Educação Profissional Paulista**

Técnico em  
**Ciência de  
Dados**

Secretaria da  
Educação



**SÃO PAULO**  
GOVERNO DO ESTADO

# **Bibliotecas: Pandas, NumPy, SciPy, Matplotlib e Seaborn**

## **Pandas – Manipulação de dados**

Aula 2

Código da aula: [DADOS]ANO1C2B4S27A2

## Mapa da Unidade 5 Componente 3

Bibliotecas: Pandas,  
NumPy, SciPy,  
Matplotlib e  
Seaborn

semana  
**23**

Pandas: Acesso e  
seleção

semana  
**25**

Pandas:  
Transformando data  
frame

semana  
**27**

**Você está aqui!**  
Pandas:  
Manipulação de  
dados

**Bibliotecas:** Pandas,  
NumPy, SciPy,  
Matplotlib e  
Seaborn

## Mapa da Unidade 5 Componente 3


# Você está aqui!

Pandas: Manipulação de datas

**Aula 2**

Código da aula: [DADOS]ANO1C2B4S27A2

**27**





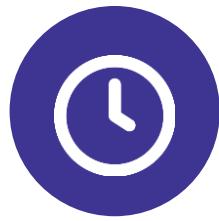
## Objetivos da Aula

- Conhecer o conceito de agrupar e resumir DataFrames usando o método *groupby* da biblioteca Pandas do Python e diferentes funções de agregação.




## Recursos Didáticos

- Recurso audiovisual para exibição de vídeos e imagens;
- Acesso ao laboratório de informática e/ou internet;
- Software Anaconda/Jupyter Notebook instalado ou similar.




## Duração da Aula

50 minutos.



## Competências Técnicas

- Ser proficiente em linguagens de programação para manipular e analisar grandes conjuntos de dados;
- Usar técnicas para explorar e analisar dados, aplicar modelos estatísticos, identificar padrões, realizar inferências e tomar decisões baseadas em evidências.



## Competências Socioemocionais

- Colaborar efetivamente com outros profissionais, como cientistas de dados e engenheiros de dados;
- Trabalhar em equipes multifuncionais, colaborando com colegas, gestores e clientes.

Construindo  
o **conceito**

## **Groupby**

O método *groupby* permite dividir um DataFrame em grupos menores com base em colunas **categóricas** e aplicar **funções de agregação**, transformação ou filtragem em cada grupo.

Com isso, vamos conhecer melhor os métodos mais comuns de agrupamento com *groupby*? Eles são de Agregação (Aggregation).

# Construindo o conceito

## Agregação (Aggregation)

Funções	Conceitos
<b>sum()</b>	Soma dos valores em cada grupo.
<b>mean()</b>	Média dos valores em cada grupo.
<b>count()</b>	Contagem de elementos em cada grupo.
<b>min()</b>	Valor mínimo em cada grupo.
<b>max()</b>	Valor máximo em cada grupo.
<b>median()</b>	Mediana dos valores em cada grupo.
<b>std()</b>	Desvio padrão dos valores em cada grupo.
<b>var()</b>	Variância dos valores em cada grupo.
<b>Nunique()</b>	Quantidade de valores únicos (distintos) em cada grupo.

Construindo  
o conceito

## Groupby

Imagine que temos **três times** de um esporte e eles jogaram várias partidas e suas pontuações estão abaixo:

Time	Pontuação
A	15
A	18
B	11
B	17
B	10
C	13

Construindo  
o conceito

## Groupby

Quantas vezes cada time teve pontuação?

Time	Pontuação
A	15
A	18
B	11
B	17
B	10
C	13

Time	Quantidade de Pontuação
A	2
B	3
C	1

# Construindo o conceito

## Groupby

Veja como é no Python:

	Time	Pontuação
0	A	15
1	A	18
2	B	11
3	B	17
4	B	10
5	C	13

```
df.groupby('Time').size()
```

```
Time
A    2
B    3
C    1
dtype: int64
```

```
df.groupby('Time').count()
```

	Pontuação
Time	
A	2
B	3
C	1

Elaborado especialmente para o curso com a ferramenta Jupyter Notebook.

Construindo  
o conceito

## Groupby

E qual é a **pontuação total** de cada time?

Time	Pontuação
A	15
A	18
B	11
B	17
B	10
C	13

Time	Pontuação
A	$15 + 18$
B	$11 + 17 + 10$
C	13

# Construindo o conceito

## Groupby

E qual é a **pontuação total** de cada time no Python?

	Time	Pontuação
0	A	15
1	A	18
2	B	11
3	B	17
4	B	10
5	C	13

```
df.groupby('Time')[ "Pontuação" ].sum()
```

```
Time
A    33
B    38
C    13
Name: Pontuação, dtype: int64
```

- ▶ Observe que agrupamos os times e somamos sua pontuação.

Elaborado especialmente para o curso com a ferramenta Jupyter Notebook.

Construindo  
o conceito

## Groupby

Qual é a pontuação **média** de cada time?

Time	Pontuação
A	15
A	18
B	11
B	17
B	10
C	13

Time	Pontuação Média
A	$(15 + 18)/2$
B	$(11 + 17 + 10)/3$
C	13

## Groupby

Pontuação **média** no Python:

	Time	Pontuação
0	A	15
1	A	18
2	B	11
3	B	17
4	B	10
5	C	13

```
df.groupby('Time')[ "Pontuação" ].mean()
```

```
Time
A    16.500000
B    12.666667
C    13.000000
Name: Pontuação, dtype: float64
```

- ▶ Observe que agrupamos os times e tiramos a média da pontuação.

Elaborado especialmente para o curso com a ferramenta Jupyter Notebook.

# Construindo o conceito

## Groupby

Qual é a pontuação **mínima** de cada time?

Time	Pontuação
A	15
A	18
B	11
B	17
B	10
C	13

Time	Pontuação Mínima
A	Menor entre 15 e 18
B	Menor entre 11, 17 e 10
C	13

# Groupby

Mínimo no Python:

	Time	Pontuação
0	A	15
1	A	18
2	B	11
3	B	17
4	B	10
5	C	13

```
df.groupby('Time')[ "Pontuação"].min()
```

```
Time
A    15
B    10
C    13
Name: Pontuação, dtype: int64
```

- ▶ Observe que agrupamos os times e selecionamos a menor pontuação.

Elaborado especialmente para o curso com a ferramenta Jupyter Notebook.

Construindo  
o conceito

## Groupby

Qual é a pontuação **máxima** de cada time?

Time	Pontuação
A	15
A	18
B	11
B	17
B	10
C	13

Time	Pontuação Máxima
A	Maior entre 15 e 18
B	Maior entre 11, 17 e 10
C	13

# Groupby

Veja como é a pontuação **máxima** no Python:

	Time	Pontuação
0	A	15
1	A	18
2	B	11
3	B	17
4	B	10
5	C	13

```
df.groupby('Time')["Pontuação"].max()
```

```
Time
A    18
B    17
C    13
Name: Pontuação, dtype: int64
```

- ▶ Observe que agrupamos os times e selecionamos a maior pontuação.

Elaborado especialmente para o curso com a ferramenta Jupyter Notebook.

Construindo  
o conceito

## Groupby

Qual é a **variação padrão da pontuação** de cada time?

Time	Pontuação
A	15
A	18
B	11
B	17
B	10
C	13

Time	Pontuação
A	Variância dos valores entre 15 e 18
B	Variância dos valores entre 11, 17 e 10
C	13

# Construindo o conceito

## Groupby

Veja como é a **variação padrão** em Python:

	Time	Pontuação
0	A	15
1	A	18
2	B	11
3	B	17
4	B	10
5	C	13

```
df.groupby('Time')[ "Pontuação" ].std()
```

```
Time
A    2.121320
B    3.785939
C      NaN
Name: Pontuação, dtype: float64
```

Observe que agrupamos os times e calculamos o desvio padrão entre os valores.

Não se preocupe com o conceito de desvio padrão agora.

Note que apareceu um **NaN** que significa *Not a Number* (não é um número). Não calculamos desvios de um valor apenas.

Elaborado especialmente para o curso com a ferramenta Jupyter Notebook.

Construindo  
o conceito

## Groupby

Qual é a quantidade de **pontuações que cada time teve**?

Time	Pontuação
A	15
A	18
B	11
B	17
B	10
C	13

Time	Pontuação
A	15 e 18 (2)
B	11, 17 e 10 (3)
C	13 (1)

# Construindo o conceito

## Groupby

No Python com **count()**:

	Time	Pontuação
0	A	15
1	A	18
2	B	11
3	B	17
4	B	10
5	C	13

```
df.groupby('Time')["Pontuação"].count()
```

```
Time
A    2
B    3
C    1
Name: Pontuação, dtype: int64
```

Elaborado especialmente para o curso com a ferramenta Jupyter Notebook.

# Construindo o conceito

## Groupby

Quantas pontuações diferentes cada time teve?  
(Quantos valores únicos de pontuação.)

Time	Pontuação
A	15
A	18
B	11
B	17
B	10
C	13

Time	Pontuação
A	15 e 18 (2)
B	11, 17 e 10 (3)
C	13 (1)

# Construindo o conceito

## Groupby

No Python, as pontuações diferentes ficam da seguinte forma:

	Time	Pontuação
0	A	15
1	A	18
2	B	11
3	B	17
4	B	10
5	C	13

```
df.groupby('Time')[ "Pontuação" ].nunique()
```

```
Time
A    2
B    3
C    1
Name: Pontuação, dtype: int64
```

- ▶ Observe que agrupamos os times e verificamos quantos valores diferentes de pontuação cada time teve.

Nesse caso, todos os valores são diferentes.


Elaborado especialmente para o curso com a ferramenta Jupyter Notebook.



© Getty Images

O que nós  
aprendemos  
hoje?

# Nuvem de palavras





© Getty Images

O que nós  
aprendemos  
hoje?

## Então ficamos assim...

- 1** Ao filtrar dados de um DataFrame selecionando linhas e/ou colunas, pode-se usar o método `.loc`.
- 2** O método `groupby` do Pandas é amplamente utilizado para agrupar dados em um DataFrame.
- 3** As agregações mais comuns são: `sum()`, `mean()`, `count()`, `min()`, `max()`, `median()`, `std()`, `var()`, `nunique()`.



# Saiba mais

**Que tal encarar o desafio de aprender Pandas em 10 minutos?**

Acesse o guia abaixo e traduza para o português para você saber tudo de Pandas em 10 minutos!

PANDAS. *User Guide: 10 minutes to pandas*, [s.d.].

Disponível em:

[https://pandas.pydata.org/pandas-docs/stable/user\\_guide/10min.html#viewing-data](https://pandas.pydata.org/pandas-docs/stable/user_guide/10min.html#viewing-data). Acesso em: 30 jul. 2024.

# Referências da aula

MCKINNEY, W. *Python para análise de dados: tratamento de dados com Pandas, NumPy & Jupyter*. São Paulo: Novatec, 2023.

PANDAS. User Guide: merge, join, concatenate and compare, [s.d.]. Disponível em: [https://pandas.pydata.org/docs/user\\_guide/merging.html](https://pandas.pydata.org/docs/user_guide/merging.html). Acesso em: 13 ago. 2024.

Identidade visual: imagens © Getty Images.

# **Educação Profissional Paulista**

Técnico em  
**Ciência de  
Dados**

Secretaria da  
Educação



**SÃO PAULO**  
GOVERNO DO ESTADO